МОСКОВСКИЙ АВИАЦИОННЫЙ ИНСТИТУТ
(НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ)

Институт №8 «Информационные технологии и прикладная математика»
Кафедра 806 «Вычислительная математика и программирование»

Лабораторная работа №4
по курсу «Параллельная обработка данных»

Сортировка чисел на GPU. Свертка, сканирование, гистограмма.

Выполнил: Г.Н. Хренов
Группа: 8О-407Б
Преподаватели: К.Г. Крашенинников,
А.Ю. Морозов

Москва, 2021

Условие

1. Цель работы: Ознакомление с фундаментальными алгоритмами GPU: свертка (reduce), сканирование (blelloch scan) и гистограмма (histogram). Реализация одной из сортировок на CUDA. Использование разделяемой и других видов памяти. Исследование производительности программы с помощью утилиты nvprof.
   Вариант 6. Карманная сортировка с битонической сортировкой в каждом кармане.

Программное и аппаратное обеспечение

GPU name: NVIDIA GeForce RTX 2060
compute capability 7:5
totalGlobalMem: 6442450944
sharedMemPerBlock: 49152
totalConstMem: 65536
regsPerBlock: 65536
maxThreadsDim: 1024 1024 64
maxGridSize: 2147483647 65535 65535
multiProcessorCount: 30
CPU name: AMD Ryzen 7 3750H with Radeon Vega Mobile Gfx
MaxClockSpeed: 2300
NumberOfCourse: 4
RAM: 8
SSD: 256, HDD: 1024
OS: Windows10
Compiler: nvcc

Метод решения

Карманная сортировка содержит все фундаментальные алгоритмы, поэтому необходимо реализовать свертку max min, гистограмму и скан, а также битоническую сортировку для кармана. После этого находим min max с помощью редукции, затем разбиваем элементы массива на малые карманы, присваивая каждому номер кармана. Далее по этим номерам выполняем сортировку подсчетом(гистограмма-скан-подсчет). Когда массив упорядочен по малым карманам, объединяем малые карманы в большие и запускаем для каждого битоническую сортировку. Если малые карманы оказались слишком велики, для них рекурсивно выполняется карманная сортировка с самого начала.

Описание программы

lab5.cu:

__global__ void kernel_reduce_max(float* data, int n, float* out) – свертка, нахождение максимального элемента

__global__ void kernel_hist(float* data, int* hist, int n, float min, float coef) – гистограмма

__global__ void kernel_pre_sort(float* data, int* count, …, float coef) – упорядочение массива по карманам

__global__ void kerel_bitonic_sort(float* data, int n, int begin) – битоническая сортировка

Результаты

	<<<64,64>>>	<<<256,256>>>	<<<512,512>>>	<<<1024,1024>>>
100	27.1us	28.3us	41.7us	43.7us
1000000	3.93ms	2.1ms	2.2ms	1.43ms
10000000	42.2ms	28.4ms	28.58ms	26.86ms
100000000	544.2ms	468.6ms	464.5ms	444.2ms

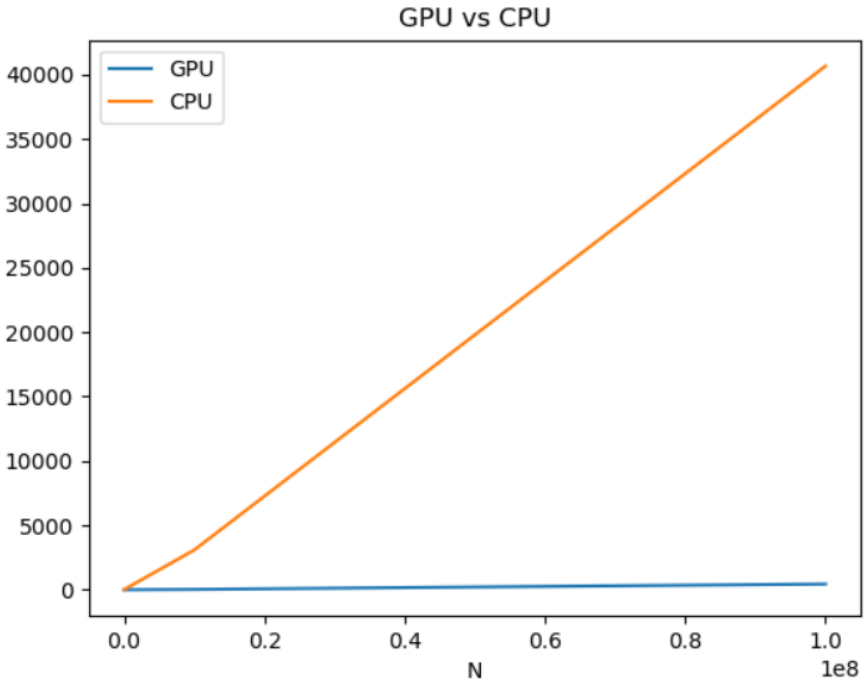

Профилировка

На всех этапах алгоритма реализация не содержит конфликтов банков памяти. В реализации битонической сортировки есть дивергенция потоков, однако это вынужденая мера, так как на длину сортируемого массива накладывются ограничения. Реализация без дивергенции возможна, но потребует дополнительных расходов по памяти и скорее всего нецесообразна.

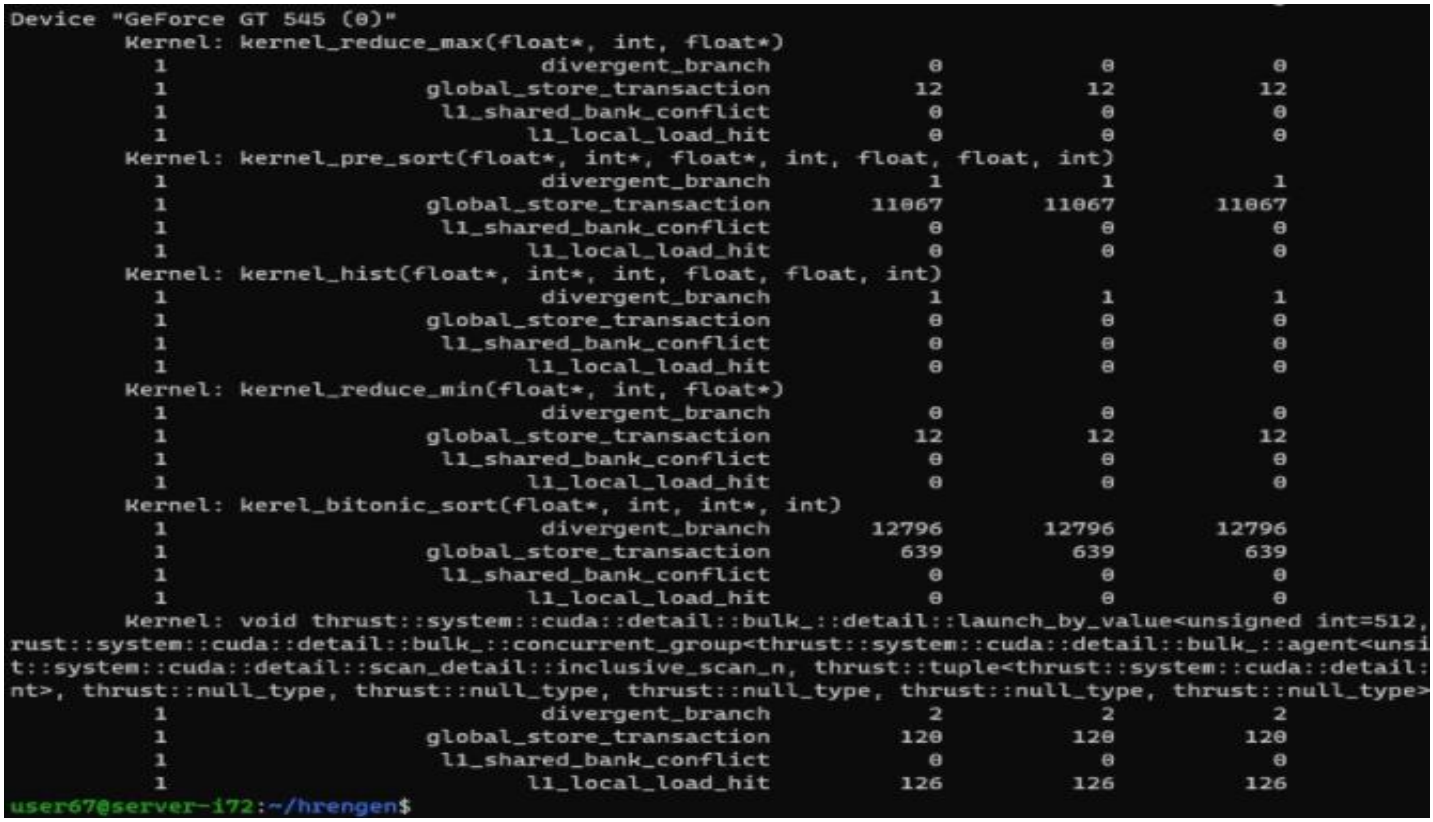

```
Device "GeForce GT 545 (0)"
        Kernel: kernel_reduce_max(float*, int, float*)
          1                            divergent_branch           0           0           0
          1                        global_store_transaction          12          12          12
          1                         l1_shared_bank_conflict           0           0           0
          1                               l1_local_load_hit           0           0           0
        Kernel: kernel_pre_sort(float*, int*, float*, int, float, float, int)
          1                            divergent_branch           1           1           1
          1                        global_store_transaction       11067       11067       11067
          1                         l1_shared_bank_conflict           0           0           0
          1                               l1_local_load_hit           0           0           0
        Kernel: kernel_hist(float*, int*, int, float, float, int)
          1                            divergent_branch           1           1           1
          1                        global_store_transaction           0           0           0
          1                         l1_shared_bank_conflict           0           0           0
          1                               l1_local_load_hit           0           0           0
        Kernel: kernel_reduce_min(float*, int, float*)
          1                            divergent_branch           0           0           0
          1                        global_store_transaction          12          12          12
          1                         l1_shared_bank_conflict           0           0           0
          1                               l1_local_load_hit           0           0           0
        Kernel: kerel_bitonic_sort(float*, int, int*, int)
          1                            divergent_branch       12796       12796       12796
          1                        global_store_transaction         639         639         639
          1                         l1_shared_bank_conflict           0           0           0
          1                               l1_local_load_hit           0           0           0
        Kernel: void thrust::system::cuda::detail::bulk_::detail::launch_by_value<unsigned int=512,
rust::system::cuda::detail::bulk_::concurrent_group<thrust::system::cuda::detail::bulk_::agent<unsi
t::system::cuda::detail::scan_detail::inclusive_scan_n, thrust::tuple<thrust::system::cuda::detail:
nt>, thrust::null_type, thrust::null_type, thrust::null_type, thrust::null_type, thrust::null_type>
          1                            divergent_branch           2           2           2
          1                        global_store_transaction         120         120         120
          1                         l1_shared_bank_conflict           0           0           0
          1                               l1_local_load_hit         126         126         126
user67@server-i72:~/hrengen$
```

Выводы

В отличие от сортировки подсчетом, карманная сортировка универсальна с точки зрения входных данных. Кроме этого, каждый ее шаг можно распараллелить и запускать на GPU. В итоге можно добиться хорошей производительности, если корректно реализовать все алгоритмы на GPU, что намного сложнее обычной реализации сортировки на CPU.